

WSI


Arkadiusz Niedzielski 283517


Cel eksperymentów: Zbadanie działania algorytmu gradientu prostego w zadaniu minimalizacji

Opis eksperymentów: Przeprowadzamy próby znalezienia minimum funkcji dla różnych wartości parametru β i różnych punktów początkowych.

Spodziewam się, że dla małych wartości β będzie potrzebna dużo iteracji aby znaleźć minimum.

1)





2) Implementacja algorytmu jest w kodzie na github.

Podjąłem decyzję żeby zakończyć działanie algorytmu jeżeli wartość funkcji w ostatnim kroku zmniejszyła się o wartość mniejszą niż $1e-7$ lub jeżeli wykonano 10000 iteracji

3)

Wyniki działania algorytmu dla funkcji $f(x)$

Beta	Initial Point	Number of Steps	Result
0.05	0.06	10000	nan
0.05	1.69	10000	nan
0.05	0.71	10000	nan
0.05	3.83	10000	nan
0.05	3.95	10000	nan
0.05	1.42	10000	nan
0.05	-3.21	10000	nan
0.05	-3.63	10000	nan
0.05	-2.06	10000	nan
0.05	-1.68	10000	nan
0.01	0.06	19	-1.4123912047137734
0.01	1.69	11	1.0125495570068523
0.01	0.71	8	1.012553977627525
0.01	3.83	10000	nan
0.01	3.95	10000	nan
0.01	1.42	10000	1.0125538340491642
0.01	-3.21	10000	nan
0.01	-3.63	10000	nan
0.01	-2.06	17	-1.4123881264639775
0.01	-1.68	15	-1.4123576547953447
0.005	0.06	18	-1.412362244957814
0.005	1.69	15	1.0125832723291883
0.005	0.71	20	1.0125345628153146
0.005	3.83	10000	nan
0.005	3.95	10000	nan
0.005	1.42	16	1.0125940294107159
0.005	-3.21	19	1.0125232418291406
0.005	-3.63	10000	nan
0.005	-2.06	9	-1.4123653851865697
0.005	-1.68	4	-1.4123744047647633
0.003	0.06	33	-1.4123543992059353
0.003	1.69	30	1.012610724163193
0.003	0.71	34	1.0125083130147958
0.003	3.83	19	-1.412355804743528
0.003	3.95	28	-1.4123559274188286
0.003	1.42	30	1.0126043860104963
0.003	-3.21	28	-1.4123554130687916
0.003	-3.63	26	1.0126063818441093
0.003	-2.06	15	-1.4123863061341702
0.003	-1.68	15	-1.4123853634289078
0.001	0.06	101	-1.4123184067035082
0.001	1.69	93	1.0126680864538942
0.001	0.71	101	1.0124457510422147
0.001	3.83	94	1.012666886170104
0.001	3.95	93	1.0126688468573584
0.001	1.42	90	1.012670629240035
0.001	-3.21	54	-1.4124223800092643
0.001	-3.63	53	-1.4124275123248349
0.001	-2.06	52	-1.4124273861093064
0.001	-1.68	49	-1.412425511968289
0.0005	0.06	200	-1.4122895462837135
0.0005	1.69	181	1.0127241307181694
0.0005	0.71	197	1.0123965793669645
0.0005	3.83	188	1.012724745927409
0.0005	3.95	188	1.0127248867437466
0.0005	1.42	175	1.0127247860211557
0.0005	-3.21	109	-1.412453713915769
0.0005	-3.63	109	-1.4124562915688113
0.0005	-2.06	105	-1.412450530165802
0.0005	-1.68	97	-1.4124565406372167
0.0001	0.06	954	-1.4121690662493842
0.0001	1.69	820	1.0129440563627345
0.0001	0.71	893	1.0121739415129016
0.0001	3.83	863	1.0129423401769786
0.0001	3.95	863	1.0129438417691168
0.0001	1.42	789	1.0129434803512436
0.0001	-3.21	512	-1.412570507206407
0.0001	-3.63	515	-1.4125708081483241
0.0001	-2.06	485	-1.4125720937859174
0.0001	-1.68	447	-1.4125720901173862
1e-06	0.06	10000	-0.027869846844961268
1e-06	1.69	10000	1.191843236075911
1e-06	0.71	10000	0.8335871640910595
1e-06	3.83	10000	1.3077138151885193
1e-06	3.95	10000	1.3096473870697976
1e-06	1.42	10000	1.1424011629329254
1e-06	-3.21	10000	-1.5539514054513404
1e-06	-3.63	10000	-1.56256498484337
1e-06	-2.06	10000	-1.5006479197940499
1e-06	-1.68	10000	-1.4591336925311496

Dla funkcji $f(x)$ duże wartości parametru beta (>0.3) dają duże ryzyko oscylacji oddalających nas od minimum, wartości beta rzędu $1e-6$ dają zbyt powolne postępy, przez co algorytm kończy się nie przez zadowalającą bliskość minimum tylko przez sztywne ograniczenie liczby iteracji. Algorytm często znajduje minimum lokale zamiast minimum globalnego.

Wyniki działania algorytmu dla funkcji $g(x_1, x_2)$

Beta	Initial Point	Number of Steps	Result
0.05	(7.65, -9.91)	10000	nan nan
0.05	(2.11, 7.1)	10000	nan nan
0.05	(-1.49, 1.63)	10000	nan nan
0.05	(0.81, 4.82)	10000	nan nan
0.05	(4.01, -7.72)	10000	nan nan
0.05	(-2.98, 3.59)	10000	nan nan
0.05	(0.08, 2.17)	10000	nan nan
0.05	(0.71, -2.5)	495	1.9341526 -2.97447775
0.05	(6.9, -7.44)	10000	nan nan
0.05	(6.63, -8.44)	10000	nan nan
0.01	(7.65, -9.91)	10000	nan nan
0.01	(2.11, 7.1)	10000	nan nan
0.01	(-1.49, 1.63)	1456	2.05564154 -3.07381671
0.01	(0.81, 4.82)	10000	nan nan
0.01	(4.01, -7.72)	1292	1.96378871 -2.91496652
0.01	(-2.98, 3.59)	10000	nan nan
0.01	(0.08, 2.17)	1452	2.03217316 -3.08663293
0.01	(0.71, -2.5)	1453	1.9138322 -2.96660163
0.01	(6.9, -7.44)	52	1.93152071 -2.93794938
0.01	(6.63, -8.44)	10000	nan nan
0.005	(7.65, -9.91)	2315	1.93432441 -2.91967817
0.005	(2.11, 7.1)	10000	nan nan
0.005	(-1.49, 1.63)	2312	1.93754699 -2.91714687
0.005	(0.81, 4.82)	2312	2.01561083 -3.10258547
0.005	(4.01, -7.72)	2314	2.04065367 -3.09546533
0.005	(-2.98, 3.59)	2315	2.06255898 -3.08278387
0.005	(0.08, 2.17)	2313	1.96387596 -2.9027285
0.005	(0.71, -2.5)	2305	1.90325044 -2.96250017
0.005	(6.9, -7.44)	2284	2.07688441 -3.06966669
0.005	(6.63, -8.44)	1169	1.93274596 -2.92098013
0.003	(7.65, -9.91)	2992	2.07152308 -3.08747336
0.003	(2.11, 7.1)	3252	1.99876948 -3.11298382
0.003	(-1.49, 1.63)	3256	1.93198828 -2.90977242
0.003	(0.81, 4.82)	3250	1.98300249 -2.88830205
0.003	(4.01, -7.72)	3256	2.04426987 -3.1039571
0.003	(-2.98, 3.59)	3242	1.93187598 -2.90985195
0.003	(0.08, 2.17)	3256	1.96066337 -2.89407792
0.003	(0.71, -2.5)	3238	1.89464448 -2.95916453
0.003	(6.9, -7.44)	3255	2.08373452 -3.07587373
0.003	(6.63, -8.44)	3254	2.07323728 -3.08604985
0.001	(7.65, -9.91)	6779	2.08590318 -3.10506035
0.001	(2.11, 7.1)	6779	2.00147793 -2.86429955
0.001	(-1.49, 1.63)	6778	1.918314 -2.89163147
0.001	(0.81, 4.82)	6779	1.97958381 -2.865833645
0.001	(4.01, -7.72)	6777	2.05317076 -3.12485869
0.001	(-2.98, 3.59)	6779	1.91818099 -2.89172946
0.001	(0.08, 2.17)	6778	1.95275595 -2.87278556
0.001	(0.71, -2.5)	6719	1.87346865 -2.95095684
0.001	(6.9, -7.44)	6778	2.10056799 -3.09112691
0.001	(6.63, -8.44)	6779	2.08795572 -3.10334322
0.0005	(7.65, -9.91)	10000	2.10003853 -3.12234801
0.0005	(2.11, 7.1)	10000	2.00172117 -2.84196546
0.0005	(-1.49, 1.63)	10000	1.90488778 -2.8738196
0.0005	(0.81, 4.82)	10000	1.97622486 -2.84376634
0.0005	(4.01, -7.72)	10000	2.06190352 -3.14536548
0.0005	(-2.98, 3.59)	10000	1.90471909 -2.87391542
0.0005	(0.08, 2.17)	10000	1.94499144 -2.85187799
0.0005	(0.71, -2.5)	10000	1.85354992 -2.9432364
0.0005	(6.9, -7.44)	10000	2.11710115 -3.10610798
0.0005	(6.63, -8.44)	10000	2.10242456 -3.12034333
0.0001	(7.65, -9.91)	10000	2.22356743 -3.27342494
0.0001	(2.11, 7.1)	10000	2.00384703 -2.64677314
0.0001	(-1.49, 1.63)	10000	1.78762469 -2.71825282
0.0001	(0.81, 4.82)	10000	1.94687618 -2.65090059
0.0001	(4.01, -7.72)	10000	2.13816711 -3.32445212
0.0001	(-2.98, 3.59)	10000	1.78708752 -2.71825436
0.0001	(0.08, 2.17)	10000	1.87719098 -2.66931114
0.0001	(0.71, -2.5)	10000	1.68063835 -2.87621641
0.0001	(6.9, -7.44)	10000	2.26156391 -3.23700893
0.0001	(6.63, -8.44)	10000	2.22881888 -3.26884983
1e-06	(7.65, -9.91)	10000	4.0805546 -5.54453669
1e-06	(2.11, 7.1)	10000	2.03633883 0.33656498
1e-06	(-1.49, 1.63)	10000	0.18308584 -0.58959525
1e-06	(0.81, 4.82)	10000	1.51443345 0.19086591
1e-06	(4.01, -7.72)	10000	3.14056273 -5.67833636
1e-06	(-2.98, 3.59)	10000	0.04050017 -0.40700726
1e-06	(0.08, 2.17)	10000	0.96381829 -0.20986489
1e-06	(0.71, -2.5)	10000	0.79870231 -2.53438074
1e-06	(6.9, -7.44)	10000	4.31032308 -5.09343561
1e-06	(6.63, -8.44)	10000	4.05363658 -5.41291209

Dla funkcji $g(x_1, x_2)$ duże wartości parametru β (>0.005) dają duże ryzyko oscylacji oddalających nas od minimum. Wartości β mniejsze niż 0.005 dają zbyt powolne postępy, przez co algorytm kończy się nie przez zadowalającą bliskość minimum tylko przez sztywne ograniczenie liczby iteracji.

Ze wzrostem β rośnie ryzyko oscylacji oddalających nas od minimum i maleje liczba iteracji potrzebnych do zadowalającego zbliżenia się do minimum.

Mniejsza β powoduje krótszy krok, a dzięki krótszemu krokowi jesteśmy w stanie bardziej się zbliżyć do minimum.

4) Algorytm gradientu prostego działa lepiej dla funkcji $g(x_1, x_2)$, ponieważ ta funkcja zawiera jedno minimum globalne i nie posiada żadnych minimów lokalnych. W tym przypadku nie ma ryzyka utknięcia algorytmu w minimum lokalnym. W otoczeniu minimum globalnego funkcji

$g(x_1, x_2)$ wartości gradientu są niskie co pozwala spokojnie dojść do minimum z niskim ryzykiem oscylacji które mogłyby nas oddalić od minimum globalnego.